

# 关于自然语言理解课题的思考

基于我在学术界科研的理解和工业界业务的感受，提供一下几个浅薄的雏形课题思想，**但是具体idea我不会明说的，明说的话我就是一作了**，供大家发挥自己主观能动性和对未来NLP的发展来思考。

## 基于CMCC34数据集来构建面向Agent客服的评测数据集

意图识别+槽位填充这种非端到端的范式落后了，现在工业界开始使用Agent流来构建智能客服了，如果还是在了一味的孤立研究，跟49年入国军无异。

不如把“与大模型竞争”变成“服务大模型”，来构建benchmark评测哪些agent框架或大模型可以很好的应用在智能客服领域上。

涉及到数据集的真实性、评测的可靠性，怎么造真实的agent-based客服对话数据集？怎么可靠评测这些模型和框架？

## 后处理增强

LRSI说到底还是双塔结构，PLM+Embedding，通过相似度来进行权重重排序，是受搜广推启发的。放到今天，也有可取之处，可以看作分类任务的“解码”工具。如果非要做分类任务的话，可以从这个角度来看，可以研究什么东西来提升大模型的分类性能，东西包含：精度、速度、显存，核心思想是成本低，效率高

## 自动化评测：LLM as a Judge

如何构建高效且可靠的评测流，是很重要的，节省大量人力物力

LLM as a Judge是不可绕过的方式，虽然它存在黑盒、不透明的问题，但也比人类评测有很突出的优势

现在的LLM as a Judge，方式很普通，调研一下就能知道了，怎么在上面弄出花来，可以从静态->动态，单模型->多模型，不可重复性->相对稳定出发

## 数据选择

在大模型预训练阶段，数据的质量和数量至关重要。

工业界在数据选择上，一般是规则+启发式过滤，验证数据质量是分批给小模型训练，看最终的benchmark性能

对数据本身缺乏相对直观的评估

之前跟智谱和上海ailab的研究员讨论过，怎样从一大堆无标签的数据中，捞出业务出发想要的的数据呢

SFTM的思想是基于KL的样本多样性与基于Logits的样本真实性，但是SFTM的数据集有标签的，显然不能直接套用

但是里面的样本多样性或许能提供某种启发，比如我收集角色扮演的相关训练数据，我想要捞一批“傲娇”相关的数据，和一批“中二”相关的数据，要怎么办？“傲娇”与“中二”在逻辑上是角色扮演数据中“不同”的数据，这个不同是不是能够代表多样性，是不是能够基于此去想一下数据捞取的idea呢？